

课程作业实验报告

基于不同文本表示的 NYT 新闻分类实验

词袋模型 平均词向量 BERT 微调

作业一

姓名：程子涵

学号：2413921

班级：物联网工程班

任务类型：英文新闻三分类

评价指标：Accuracy 与 Macro-F1

摘要

本文在 NYT 新闻三分类任务上比较 Binary BoW、Word Frequency、GloVe、基于 AG News 和 NYT 的 Word2Vec，以及 BERT 微调六种方法。五种传统表示均结合 Logistic Regression，六组实验共用去重后的 80% / 10% / 10% 数据划分，以 Accuracy 和 Macro-F1 评价分类效果，并结合词向量覆盖率、分类别 F1、混淆矩阵和训练曲线进行分析。

在固定随机种子和预设参数下，GloVe 的测试 Accuracy 为 0.9852，Macro-F1 为 0.9601，均为六组最高；Word Frequency 和 BERT 的 Macro-F1 分别为 0.9572 和 0.9525。目标领域 NYT Word2Vec 优于外部 AG News Word2Vec。错误主要集中在 business 与 politics 之间，说明类别边界交叉仍是主要困难。结果表明，文本表示、领域匹配和实验约束共同影响分类表现；本研究仅基于单次固定划分，尚不能给出统计显著性或普遍最优结论。

关键词：新闻分类；词袋模型；GloVe；Word2Vec；BERT；Macro-F1

目录

摘要	I
1 引言	1
2 数据与实验协议	1
2.1 评价指标	2
3 方法与参数设置	2
3.1 词袋表示与逻辑回归	2
3.2 平均词向量表示	2
3.3 BERT 微调	3
4 实验结果与比较	4
5 词向量覆盖率与分类别表现	5
6 BERT 训练过程与运行环境	6
7 混淆矩阵与错误分析	8
7.1 可追溯错误案例	8
8 总结与讨论	9
8.1 主要结论与研究限制	9
8.2 实验思考	9
8.3 后续研究方向	10
参考资料	10

1 引言

新闻分类将非结构化文本映射为离散主题标签，是检验文本表示有效性的一种直接方式。稀疏词袋强调词汇分布，平均词向量引入连续语义表示，BERT 则通过上下文编码学习任务相关特征。本实验在统一数据划分与评价协议下，观察这些表示方式在同一目标任务上的表现差异。

本实验按照作业要求，在 NYT 新闻三分类任务上比较两种词袋表示、三种 100 维词向量表示和 BERT 微调，共六组方法。传统方法使用 Logistic Regression，所有方法使用相同的数据划分，以测试集 Accuracy 和 Macro-F1 评价。

在本次固定划分和参数设置下，GloVe 的测试 Accuracy 为 0.9852、Macro-F1 为 0.9601，均为六组最高；Word Frequency 的 Macro-F1 为 0.9572，BERT 为 0.9525。复杂模型在本实验条件下没有必然优势。该结论仅描述本次运行，不代表多次随机实验的统计显著性结论。

2 数据与实验协议

原始 NYT 含 11,519 条记录。预处理先删除 72 条完全相同的重复文本，保留首次出现的记录，得到 11,447 条；若重复文本标签冲突则停止运行。原始 CSV 未被改写。去重是防止同一文本跨集合出现的额外处理，作业文档未明确要求；因此报告明确披露样本数量变化。

使用 NumPy RandomState(42) 随机打乱去重后的样本，再按 80% / 10% / 10% 划分。训练集和验证集数量向下取整，余数归测试集。采用普通随机划分而非分层抽样；六组实验共享原始行号清单，三对集合间完全相同文本交集均为 0。

表 1: 数据划分与类别分布

集合	business	politics	sports	合计
训练集	1148	1143	6866	9157
验证集	140	148	856	1144
测试集	129	142	875	1146

AG News 共 90,000 条文本，仅用于外部 Word2Vec 的无监督训练。NYT Word2Vec 仅使用 NYT 训练集学习词向量，词袋词表亦仅由训练集建立，验证集与测试集不参与特征学习或分类器拟合。

所有超参数预先固定，验证集用于监测和报告；未进行验证集网格搜索，也未合并 train+val 重训。作业未要求这两项操作。测试集仅用于最终评价，不根据测试得分回调参数。

2.1 评价指标

Accuracy 为正确分类数占测试样本数的比例。每类 F1 由精确率 P 与召回率 R 计算，Macro-F1 为三个类别 F1 的算术平均。

$$\text{Accuracy} = \frac{N_{\text{correct}}}{N_{\text{test}}}, \quad F_{1,c} = \frac{2P_c R_c}{P_c + R_c}, \quad \text{Macro-}F_1 = \frac{1}{3} \sum_{c=1}^3 F_{1,c}. \quad (1)$$

测试集 sports 占 76.35%，因此同时报告 Macro-F1 和分类别指标以避免多数类掩盖少数类误差。

3 方法与参数设置

传统方法采用“分词—文档表示—逻辑回归—类别预测”的统一流程，BERT 使用“预训练分词—上下文编码—分类头微调”的流程。统一划分保证各方法面对相同样本；表示维度、预训练语料和输入长度仍存在差异，因此比较反映的是本次完整配置下的实际表现。

3.1 词袋表示与逻辑回归

Binary BoW 用 0/1 表示词是否出现；Word Frequency 使用原始出现次数，不做 TF-IDF 加权或长度归一化。两者训练词表大小均为 65,902，采用稀疏矩阵保存文档向量。作业明确列出两种方法，本实验完成这两项。

Task 1 和 Task 2 统一先小写化，再用正则 $[a-zA-Z](?:'[a-zA-Z])?|\d+$ 分词，保留英文词、词内撇号和数字。不依赖 NLTK 或 punkt，避免跨环境自动切换分词器；作业对 NLTK 的表述为可考虑使用。BERT 使用其预训练 tokenizer。

五组传统模型均采用 LogisticRegression: C=1.0、solver=lbfgs、L2 正则、max_iter=2000、random_state=42、class_weight=None。未额外重采样或类别加权。五组实际迭代数依次为 20、122、57、34、27，日志均确认收敛；迭代上限本身不保证收敛。

3.2 平均词向量表示

设文档中能够查到向量的词出现序列为 $V(d)$ ，词向量为 $\mathbf{e}(w)$ ，则文档表示为

$$\mathbf{v}(d) = \frac{1}{|V(d)|} \sum_{w \in V(d)} \mathbf{e}(w). \quad (2)$$

这种表示将文档压缩为固定的 100 维向量，便于复用同一分类器；同时，平均操作不保留词序，也会削弱少量关键词与长距离关系的影响。该性质用于解释表示能力的差异，不等于对具体错误样本的模型归因。

预训练 GloVe 使用 glove.6B.100d.txt，共 400,000 个词，每词 100 维。对每篇文档中可查到词向量的所有词出现取算术平均，重复词按出现次数参与平均；未登录词跳过，若无有效词则返回全零向量。本次三组词向量实验在三个集合中均无全零文档。

表 2: Word2Vec 训练配置

项目	Word2Vec AG	Word2Vec NYT
训练语料	AG News 全部文本	NYT 训练集
文档数	90,000	9,157
向量维度	100	100
词表大小	23,529	29,066
模型与窗口	Skip-gram / window=5	Skip-gram / window=5
最低词频与轮数	min_count=5 / epochs=10	min_count=5 / epochs=10

两组 Word2Vec 其余参数一致：negative=5、hs=0、sample=0.001、alpha=0.025、min_alpha=0.0001、seed=42、workers=1、ns_exponent=0.75、sorted_vocab=1、shrink_windows=True、batch_words=10000；使用稳定 SHA256 词哈希减小跨进程随机性。

3.3 BERT 微调

模型为 google-bert/bert-base-uncased；max_length=64，包含特殊 token，超长文本截断，不足长度补齐。训练 3 epochs，训练和评价 batch_size=16，AdamW，初始学习率 2e-5，weight_decay=0.01，线性学习率衰减，无 warmup。随机种子和 data_seed 均为 42，启用 full_determinism。

每轮结束评价验证集，完整训练第 3 轮后保存模型和 tokenizer，并使用该最终模型评价测试集。运行设备为 Colab Tesla T4，累计 1,719 个优化步骤，实际完成 3.0 epochs。

4 实验结果与比较

表 3: 六组方法的验证集与测试集结果

方法	验证 Acc	验证 F1	测试 Acc	测试 F1
Binary BoW	0.9808	0.9529	0.9808	0.9478
Word Frequency	0.9816	0.9570	0.9825	0.9572
GloVe	0.9764	0.9423	0.9852	0.9601
Word2Vec AG	0.9650	0.9166	0.9738	0.9335
Word2Vec NYT	0.9747	0.9392	0.9817	0.9566
BERT	0.9747	0.9444	0.9791	0.9525




图 1: 六组方法的验证集与测试集指标。F1 为 Macro-F1，点旁数字为百分数，横轴局部放大以便观察差异。

Word Frequency 相比 Binary BoW，测试 Accuracy 提高 0.17 个百分点，Macro-F1 提高 0.94 个百分点，说明在本次数据上保留词频比只保留是否出现略有优势。两者都保留了完整文档的词汇统计，但不表达词序。

GloVe 比 Word Frequency 的测试 Accuracy 高 0.26 个百分点，Macro-F1 高 0.29 个百分点，差异较小，不能仅据一次运行断言普遍优越。GloVe 的测试得分高于验证得分反映了集合样本组成差异，不能据此认定验证集参与了训练。

本次 BERT 测试 Accuracy 为 0.9791、Macro-F1 为 0.9525，低于 GloVe 和 Word Frequency。长度上限 64 限制了可见上下文，而词袋与词向量方法处理全文；这一差异可能影响表现，但尚无长度消融实验，不能视为已证实的因果解释。

5 词向量覆盖率与分类别表现

表 4: 词向量的 token 覆盖率

表示方法	训练词覆盖率	验证词覆盖率	测试词覆盖率
GloVe	98.18%	98.14%	98.15%
Word2Vec AG	95.79%	95.83%	95.92%
Word2Vec NYT	98.90%	98.54%	98.55%

覆盖率按 token 出现次数计算，不是独立词种比例。NYT Word2Vec 的测试词覆盖率为 98.55%，高于 AG Word2Vec 的 95.92%；前者 Macro-F1 高 2.31 个百分点。尽管 AG 文档数更多，其领域和文本长度不同，文档数并不等于有效词规模，结果与目标领域匹配的重要性一致。

GloVe 的测试覆盖率为 98.15%，略低于 NYT Word2Vec，但 Macro-F1 更高，说明覆盖率不能单独解释效果。预训练语料规模、向量质量以及平均池化对语义信息的损失都可能影响分类。




图 2: 各方法在测试集上的分类别 F1。固定色阶为 0.85 至 1.00，单元格显示百分数。

六种方法在 sports 上的 F1 均超过 0.993，而 business 与 politics 的 F1 约为 0.900 至 0.945。sports 样本占比高且主题词明显，整体 Accuracy 因而高于 Macro-F1。Word Frequency 的 business F1 为 0.9416，高于 GloVe 的 0.9365；GloVe 在 politics 和 sports 上更好，最终获得更高的平均 F1。

6 BERT 训练过程与运行环境




图 3: BERT 的训练日志与轮末验证指标。训练 loss 为日志区间平均，验证 loss 为完整验证集评价，两者采样粒度不同。

表 5: BERT 各轮验证指标

Epoch	验证 Loss	验证 Accuracy	验证 Macro-F1
1	0.0917	0.9738	0.9425
2	0.0877	0.9764	0.9475
3	0.0971	0.9747	0.9444

训练 loss 整体下降，第 2 轮验证 Macro-F1 为 0.9475，第 3 轮降为 0.9444，同时验证 loss 回升。这提示可能出现轻度过拟合，也可能包含单次训练波动。实验仍按预先约定使用第 3 轮模型，没有依据测试集或验证集改选轮次。

表 6: 各方法日志总耗时与执行环境

方法	日志总耗时秒	执行环境
Binary BoW	6.99	Windows / CPU
Word Frequency	16.36	Windows / CPU
GloVe	30.38	Windows / CPU
Word2Vec AG	329.31	Windows / CPU
Word2Vec NYT	456.20	Windows / CPU
BERT	466.35	Colab / Tesla T4

总耗时为 Experiment 初始化后至结果保存期间的计时，包含特征构建、训练及输出等开销，不等同于纯训练时间；数据划分发生在计时之前。BERT 的训练段耗时为 414.31 秒。CPU 和 GPU 平台、软件版本及初始化开销不同，表中耗时只能说明本次运行成本，不能直接比较算法速度。

传统方法环境: Python 3.13.9、NumPy 2.3.5、pandas 2.3.3、scikit-learn 1.7.2、gensim 4.4.0。BERT 环境: Python 3.13.15、PyTorch 2.11.0+cu128、CUDA 12.8、transformers 4.56.2、accelerate 1.10.1、scikit-learn 1.6.1。完整依赖版本随每次实验保存。

7 混淆矩阵与错误分析




图 4: 六种方法的测试混淆矩阵。行为真实类别，列为预测类别；数字同时列出样本数及行归一化百分比。

六组方法错误数依次为 22、20、17、30、21、24。GloVe 的 17 个错误中，business→politics 为 10 个、politics→business 为 5 个，二者合计占 88.24%；BERT 的对应交叉误判共 13 个，占其 24 个错误的 54.17%。商业与政策主题交叉是主要困难，但 BERT 还存在更多涉及 sports 的错误。

7.1 可追溯错误案例

原始 CSV 数据行 `source_row=8022` (从 0 起计，不含表头): 报道联邦预算削减对机场和航班的影响，真实类别为 politics，GloVe 和 BERT 均预测为 business。政府预算与航空业经营词汇同时出现，主题边界具有交叉性。

`source_row=11007`: 报道警方拘捕从事投资风险调查的咨询人士，真实类别为 business，GloVe 预测为 politics。警方、逮捕等词语可能强化政治或公共事务信号，而商业调查背景决定了原始标签。

`source_row=8246`: 报道以万亿美元硬币应对债务上限的讨论，真实类别为 business，BERT 预测为 politics。白宫与国会冲突和经济政策在同一文本中交织。以上为结合文本的定性解释，不等于已经验证的模型归因。完整原文及预测见各实验 `test_errors.csv`。

8 总结与讨论

8.1 主要结论与研究限制

本次结果表明，传统词汇特征已能很好地区分 NYT 三类新闻；100 维平均 GloVe 在固定实验条件下取得最高测试指标。使用 NYT 训练语料学习 Word2Vec，比使用 AG News 得到更好的目标任务效果；BERT 在 64 token、3 epochs 的约束下没有超过最佳传统方法。

实验的限制包括：只使用一次固定随机划分和一个随机种子，没有置信区间或显著性检验；没有超参数搜索、类别加权对照和 BERT 长度消融；完全重复文本去重不能排除语义相近新闻。

8.2 实验思考

1. 模型复杂不一定效果更好。

这次实验中，GloVe 的测试集指标最高，BERT 没有超过它。我觉得模型效果不只取决于模型有多复杂，也和任务特点、文本长度以及数据规模有关。对于新闻分类，许多类别本身就有比较明显的词汇特征，传统方法也能取得不错的结果。

2. 不能只看 Accuracy。

测试集中 sports 样本比 business 和 politics 多得多，因此模型即使主要分对了 sports，也可能得到较高的 Accuracy。结合 Macro-F1 和各类别 F1 后，可以看到 business 和 politics 更容易被混淆，模型在少数类别上的表现需要单独关注。

3. 文本表示方式会影响模型能捕捉到的信息。

Binary BoW 只记录词是否出现，Word Frequency 还保留词语出现次数，平均词向量则把词语映射到连续空间。这些表示各有侧重。实验中 Word Frequency 略好于 Binary BoW，也让我看到词频信息确实可能对分类有帮助，不过不同方法之间的差距还需要结合具体数据来理解。

4. 有些分类错误来自新闻主题交叉。

错误案例中，有的文章同时讨论政府政策和商业影响，模型把真实的 business 文章预测为 politics，或反过来。这些新闻的主题边界并不总是清楚，分类错误不一定只是模型没有学好，也可能说明标签体系和文本内容存在交叉。

5. 实验结论依赖公平、可追溯的比较。

所有方法使用相同的数据划分，训练参数和预测结果也有记录，这能让我有依据地比较模型。如果每种方法采用不同的数据划分，结果差异就可能来自数据本身，而不是模型。

6. 一次结果还不足以说明普遍规律。

这次实验使用固定随机种子和一份数据划分，得出的结论只适用于当前实验设置。若继续研究，我想尝试不同随机种子，并调整 BERT 的最大文本长度，观察结果是否稳定，以及较长文本是否能改善分类表现。

8.3 后续研究方向

后续可在保持数据划分协议和测试集独立性的前提下，使用多个随机种子重复实验，报告均值与波动范围；对 BERT 输入长度进行受控对比，以检验截断是否影响效果；针对 business 与 politics 的交叉样本进一步检查文本与标签边界。这些均属于待开展的扩展研究，不计入本次实验结果。

参考资料

- [1] 课程提供的作业一要求文档。实验任务、数据划分、评价指标与提交要求。
- [2] 课程提供的 nyt.csv 与 ag.csv。NYT 分类数据与 AG News 词向量训练语料。
- [3] Stanford NLP。GloVe 预训练词向量 glove.6B.100d。http://nlp.stanford.edu/data/glove.6B.zip。
- [4] Google BERT。google-bert/bert-base-uncased。https://huggingface.co/google-bert/bert-base-uncased。模型 revision: 86b5e0934494bd15c9632b12f734a8a67f723594。